


結果1：真の局所特徴を選べるか

非線形・相関・ノイズを含む30次元BB。各点の真のA/B勾配Top-5を数値計算

評価指標：各説明点で、AとBの確率比を実際に動かしている「本当に重要な特徴」上位5個をあらかじめ数値計算で求めておき、各手法が選んだ上位5特徴と何個一致したかを再現率として測る

真の局所Top-5特徴の再現率



全条件平均

OVR 0.820

2クラス通常LIME 0.913

Contrastive 0.926

OVO Logistic 0.874

3方式とも

OVRより全6条件で有意

Holm補正後

なぜ差が出るか：OVRは「A対それ以外全部」の確率を回帰するため、AとBを分ける特徴が他クラスの情報に埋もれやすい。2クラスに絞ると、AB間の違いに直接効く特徴だけが残りやすくなる。


このスライドの主張：2クラスに絞ることで、本当に効いている特徴をより正確に選べる（+0.05～0.11pt）

結果2：未知の近傍でも判定を再現できるか

結果1と同じ非線形BBで、学習に使っていない400摂動上のA/B判定を評価

評価指標：学習には使っていない未知の摂動点400個を用意し、各手法の説明が「AとBどちらが優勢か」をブラックボックスの実際の判定とどれだけ一致させられるかを測る

未使用摂動でのA/B符号忠実度



全条件平均

OVR 0.887

2クラス通常LIME 0.898

Contrastive 0.901

OVO Logistic 0.894

改善は約1ポイント

大差ではない

3方式とも6/6条件で有意

なぜ検証するか：学習に使った摂動点だけで良い結果が出ても、過学習の可能性が残る。未知の400点で改めて評価することで、結果1の関連性の改善が精度の犠牲の上に成り立っていないかを確認している。

このスライドの主張：精度をほとんど落とさずに、結果1の関連性の改善を得られている

関連研究①：One-vs-One


GANMEXが提案したこと

- ・ One-vs-One Attributionという考え方を提案：クラス全部ではなく、特定の2クラスだけと比較する
- ・ 2クラスに絞ることで、両クラスに共通する特徴ではなく、2クラスを区別する特徴に注目できる
- ・ やり方：GANで比較クラスの「もしこの画像が別クラスだったら」という画像を生成し、元の画像との違いをattributionの基準にする（画像分類が対象）

本研究が活かす点・違う点

- ・ 「特定の2クラスを比較する」という問いの立て方はそのまま採用する
- ・ ただし画像やGANのような生成モデルには依存しない
- ・ LIMEの局所線形モデルに置き換えることで、一般の表形式データにもOne-vs-One的な説明を作れるようにする

このスライドの主張：『特定の2クラスを比較する』という問いを、画像に限らず一般の表形式データへ拡張する



2クラスを区別する境界のイメージ
（表形式データでの模式図）

関連研究②：log-oddsを局所的に説明する

CLIMAXは、ブラックボックス分類器を局所的な分類モデルで説明する方法を提案している

CLIMAXが提案したこと

- ・ ブラックボックスを局所的な小さいモデルで説明する
- ・ 対象クラス対数の対数オッズを回帰する（L-CLIMAX）
- ・ 確率を交差エントロピーで回帰する（CE-CLIMAX）：極端な確率でも学習が不安定になりにくい

本研究が活かす点・違う点

- ・ 確率をそのまま見ず、対数比や交差エントロピーで近似するという当てはめ方を採用する
- ・ ただし比較対象は「それ以外全部」ではなく、予測1位・2位という特定の2クラスに絞る
- ・ クラス数が多いほど、この絞り込みの効果が大きくなる（下記参照）

CLIMAXが回帰する量（参考）と、本研究との違い

$\log (p_A(z) / (1-p_A(z))) \approx \beta \cdot z + b$ （CLIMAX：比較対象は「A 対 それ以外すべて」）

$1-p_A(z) = p_B(z) + p_C(z) + p_D(z) + \dots$ のように、Aと競合しない他クラスの確率まで一緒に足し込まれる。クラス数が増えるほどこの合算が薄まり、本当の競合相手Bとの違いが見えにくくなる。本研究はこれを $p_B(z)$ だけに絞ることで、Bとの違いに直接効く成分を残す。

このスライドの主張：確率でなく対数比・交差エントロピーで近似する当てはめ方を、Top-2の2クラスに絞って使う

まとめと今後の展望

本編で示した価値を3点に絞って振り返り、残る課題を示す

関連性

「AとBの違い」を
直接説明できる

真の局所Top-5再現率：OVR 0.82 → 2クラス方式 0.87～0.93
（+0.05～0.11pt、全6条件で有意）

忠実度

従来（OVR）より
精度は落ちない

held-out符号忠実度：OVR 0.887 → 2クラス方式 0.894～0.901（改
善は約1ポイントで大差ではない）

効率

クラス数に対して
ほぼ一定

計算時間：C=10でOVR 63.46ms、2クラス方式は6.5ms前後（約10
分の1、クラス数が増えても変わらない）

今後の展望

1. 解釈性の向上を定量的に測る方法の検討

既知の真値への関連性は測れたが、実際に人が説明を見て理解しやすいと感じるかは未検証。ユーザー評価などが必要

2. 実データでの検証

今回はすべて人工的に生成したデータ。実際のデータセットでも同じ傾向が出るかを確認する

3. 競合クラスがTop-2以外や入力ごとに変わる場合への対応

今回は予測1位・2位を固定して比較した。3位以下との比較や、入力によって競合クラスが変わる場合は未検証